

Rapport d'Évaluation du Modèle d'Analyse de Sentiments


1. Introduction

Ce rapport présente l'évaluation des performances du modèle de `LogisticRegression` développé pour analyser les sentiments (positifs et négatifs) des tweets, conformément aux exigences du TP.


2. Matrices de Confusion

Le modèle génère des scores pour les prédictions positives et négatives. Les matrices de confusion ci-dessous (générées via `evaluate_model.py`) illustrent les performances du modèle sur les données annotées de la table `tweets`.

- **Matrice de Confusion pour les prédictions Positives** : Évalue la capacité du modèle à identifier correctement les tweets positifs par rapport au reste.



- **Matrice de Confusion pour les prédictions Négatives** : Évalue la capacité du modèle à identifier correctement les tweets négatifs par rapport au reste.



3. Analyse des Performances

Les mesures de performances (Précision, Rappel et F1-Score) calculées sur le jeu de données révèlent les points suivants :

Précision, Rappel et F1-Score

- **Précision** : Indique le pourcentage de prédictions correctes parmi toutes les prédictions positives (ou négatives).
- **Rappel** : Indique le pourcentage de vrais positifs (ou négatifs) correctement identifiés par le modèle.
- **F1-Score** : Moyenne harmonique de la précision et du rappel, fournissant une vue équilibrée des performances.

Résultats de l'évaluation sur le jeu de validation (25% des données) :

	precision	recall	f1-score	support
-1	0.00	0.00	0.00	2.0
1	0.00	0.00	0.00	0.0
accuracy			0.00	2.0
macro avg	0.00	0.00	0.00	2.0
weighted avg	0.00	0.00	0.00	2.0

Analyse : Actuellement, le jeu de données initial (inséré via `init.sql`) ne contient que 8 tweets. Lors de la séparation des données (75% entraînement, 25% validation), le jeu de validation ne contenait que 2 tweets (tous de classe négative `-1`). Le modèle, s'étant entraîné sur très peu de données, n'a pas réussi à les classifier

correctement (précisant des scores de 0). Cela illustre parfaitement la nécessité absolue d'avoir un dataset beaucoup plus large pour que le modèle puisse apprendre et généraliser correctement.

Observations sur les erreurs fréquentes et biais éventuels

- **Biais de mots-clés** : Les modèles basés sur TF-IDF ont tendance à sur-pondérer certains mots (ex: "génial", "nul"). Si ces mots sont utilisés dans un contexte sarcastique (ex: "C'est vraiment génial... de perdre mon temps"), le modèle risque de se tromper.
- **Données limitées** : Avec un petit nombre de données, le modèle n'a pas la capacité de généraliser à des formulations complexes ou du vocabulaire nouveau.

4. Recommandations

Pour améliorer les performances de l'API d'analyse de sentiments :

1. **Augmentation du jeu de données** : Annoter plus de tweets pour exposer le modèle à un vocabulaire plus varié.
2. **Gestion du Sarcasme et de l'Ironie** : Les modèles de régression logistique avec TF-IDF peinent sur ces aspects. Passer à des embeddings plus complexes (comme Word2Vec, BERT) permettrait de capturer le contexte sémantique.
3. **Hyperparamètres** : Optimiser les paramètres de la **LogisticRegression** (par exemple la régularisation **C**) via une recherche en grille (GridSearch) sur un plus grand jeu de validation.